

**UNIVERSIDADE FEDERAL DE SANTA CATARINA
PROGRAMA DE PÓS GRADUAÇÃO EM ENGENHARIA DE
AUTOMAÇÃO E SISTEMAS**

**ESTUDO DE TÉCNICAS PARA PREDIÇÃO DE
MANCHAS DE ALAGAMENTO UTILIZANDO
REDES NEURAIS ARTIFICIAIS**

PROJETO DE DISSERTAÇÃO DE MESTRADO

Thiago Vaz Simas dos Santos

Orientador: Prof. Dr. Rodolfo César Costa Flesch

Coorientador: Prof. Dr. Laio Oriel Seman

Florianópolis, SC, Brasil

SUMÁRIO

1 INTRODUÇÃO	2
1.1 Problema de pesquisa	3
1.2 Objetivos	4
1.2.1 Objetivo geral	4
1.2.2 Objetivos específicos	5
1.3 Organização do trabalho	5
2 REVISÃO DA LITERATURA	7
2.1 A predição de alagamentos urbanos: Visão geral e trabalhos correlatos	7
2.1.1 A predição de manchas de alagamentos em ambientes urbanos sensorizados e sua modelagem básica	8
2.1.2 O uso de sensores ambientais e dados IoT em contextos urbanos	12
2.1.3 Modelos baseados em aprendizado de máquina tradicional e as redes neurais profundas	14
2.1.3.1 Modelos tradicionais de aprendizado de máquina	14
2.1.3.2 Redes neurais profundas	16
2.1.3.3 Comparativo e tendências	18
2.1.4 Arquiteturas híbridas e tendências recentes	19
2.1.5 Trabalhos recentes e o uso de redes neurais para a predição de manchas de alagamentos urbanos	21
2.1.6 Lacunas e oportunidades na literatura existente	22
2.2 A modelagem de séries temporais ambientais para a predição de alagamentos	24
2.2.1 Estrutura e propriedades de séries ambientais multivariadas	25
2.2.2 Estratégias de janelamento, normalização e modelagem	28
2.2.3 Desafios em dados reais: ruído, sazonalidade e dados ausentes	31
3 METODOLOGIA	36
4 RELAÇÃO DE PERIÓDICOS E EVENTOS CIENTÍFICOS COM POTENCIAL PARA PUBLICAÇÃO	38
5 RECURSOS	40
REFERÊNCIAS	41

1 INTRODUÇÃO

A previsão de eventos hidrológicos extremos, como alagamentos urbanos, representa um dos principais desafios contemporâneos no contexto da gestão de desastres naturais e do planejamento urbano (GUO; GUAN; YU, 2021; PIADEH; BEHZADIAN; ALANI, 2022). As manchas de alagamento, pontuais áreas sujeitas ao acúmulo de água devido à insuficiência do escoamento superficial, são resultado da interação entre múltiplas variáveis meteorológicas, geográficas, e hidrológicas (LEI et al., 2021). A modelagem e previsão desses eventos exigem metodologias capazes de lidar com sistemas dinâmicos, não lineares e, muitas vezes, marcados por dados incompletos ou ruidosos, como as oferecidas por métodos de aprendizado de máquina e redes neurais artificiais (LI et al., 2025).

Nos últimos anos, com o avanço da Internet das Coisas (IoT, do inglês *Internet of Things*) e da infraestrutura de sensoriamento ambiental, tem-se possibilitado a coleta de grandes volumes de dados em tempo real, como medições de nível de água, velocidade do vento, temperatura e precipitação (ZAKARIA; JABBAR; SULAIMAN, 2023; NARAYANA et al., 2024). Este novo cenário favorece o uso de abordagens baseadas em aprendizado de máquina e redes neurais, que se destacam por sua capacidade de capturar padrões em dados multivariados e de lidar com não linearidades sem a necessidade de modelagens explícitas do sistema físico (ESKANDARIAN et al., 2022; AHMED; RIO-CHANONA; MERCANGÖZ, 2023).

Com o avanço da ciência de dados e das tecnologias de sensoriamento distribuído, tornou-se possível coletar grandes volumes de dados ambientais, possibilitando o uso de modelos baseados em aprendizado de máquina para previsão de alagamentos (ZHOU et al., 2023; YU et al., 2023). Arquiteturas como redes neurais recorrentes do tipo Memória Longa de Curto Prazo (LSTM, do inglês *Long Short-Term Memory*), Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) e, mais recentemente, modelos baseados em atenção, como os Transformers, têm se destacado pela capacidade de capturar padrões temporais e espaciais em dados dinâmicos multivariados ao longo do tempo (HOCHREITER; SCHMIDHUBER, 1997; VASWANI et al., 2017).

Além das LSTMs e Transformers, pesquisas recentes têm buscado aprimorar essas arquiteturas por meio da incorporação de mecanismos de atenção temporal e espacial, normalizações adaptativas e estratégias híbridas (CAO et al., 2025; CHOI et al., 2025). Adicionalmente, tem crescido o interesse em arquiteturas que combinam LSTM, atenção e Redes de Convolu-

ções Temporais (TCNs, do inglês *Temporal Convolutional Networks*), visando capturar tanto padrões locais quanto dependências de longo prazo (ZHANG et al., 2023; XU et al., 2021). Essas abordagens híbridas têm se destacado em estudos de referência relacionados à previsão da vazão de rios, detecção de enchentes e simulações hidrodinâmicas urbanas (SONG; GUAN; YU, 2025; GUAN et al., 2024).

Apesar dos avanços observados no desenvolvimento de modelos híbridos e na aplicação de redes neurais artificiais para a predição de manchas de alagamentos, estudos recentes apontam limitações importantes, como a necessidade de grandes volumes de dados para treinamento, a sensibilidade a dados ausentes e a dificuldade de generalização para diferentes regiões geográficas (OKACHA et al., 2024; ZHANG et al., 2022). Nesse contexto, torna-se relevante investigar o desempenho dessas arquiteturas em cenários reais, especialmente na predição de manchas de alagamento em ambientes urbanos sensorizados, de forma a contribuir para o aprimoramento e a robustez de sistemas preditivos (SITU et al., 2024; WANG et al., 2024).

Além disso, a aplicação dessas abordagens em ambientes urbanos brasileiros ainda apresenta desafios significativos a serem explorados e grande parte dos estudos disponíveis na literatura internacional concentra-se em cenários específicos de países desenvolvidos, onde há maior disponibilidade de infraestrutura, monitoramento e dados ambientais de alta qualidade (NKWU-NONWO; WHITWORTH; BAILY, 2020; GUO; GUAN; YU, 2021). No contexto brasileiro, especialmente em grandes centros urbanos, observa-se uma carência de investigações que avaliem a aplicabilidade e a robustez desses modelos diante de condições adversas, como dados ruidosos, lacunas de medição contínua e elevada variabilidade climática e geográfica (SOARES et al., 2025; RASHEED et al., 2024). Diante desse cenário, este trabalho busca contribuir para o avanço da pesquisa na área ao propor uma análise exploratória da eficácia referente a diferentes arquiteturas de redes neurais aplicadas à predição de manchas de alagamento em ambientes urbanos sensorizados.

1.1 Problema de pesquisa

A predição de manchas de alagamento em áreas urbanas tem se consolidado como uma necessidade crítica frente ao aumento da frequência e intensidade de eventos climáticos extremos. Este problema está inserido em um contexto complexo, marcado pela interação entre múltiplas variáveis hidrológicas, meteorológicas e topográficas. Modelar tais fenômenos é desafiador não apenas pela complexidade do ambiente físico envolvido, mas também pelas carac-

terísticas intrínsecas dos dados: não linearidade, alta dimensionalidade, ruídos, sazonalidades irregulares e lacunas nas séries temporais (MOSAVI; OZTURK; CHAU, 2018; SYEED et al., 2022).

Tradicionalmente, métodos estatísticos e modelos hidrológicos baseados em equações diferenciais foram amplamente utilizados para a previsão de alagamentos (SEYDI et al., 2022; BEVEN, 2011). No entanto, essas abordagens geralmente requerem conhecimento detalhado do sistema físico e podem apresentar baixo desempenho em cenários urbanos, onde a variabilidade e a imprevisibilidade são acentuadas (SEYDI et al., 2022; LIU et al., 2020). Nesse contexto, técnicas de aprendizado de máquina, mais especificamente, redes neurais profundas, vêm ganhando destaque, uma vez que são capazes de capturar padrões complexos diretamente a partir de dados, sem a necessidade de modelagens explícitas do sistema (LÖWE et al., 2021; BENTIVOGLIO et al., 2022; WANG et al., 2024).

Arquiteturas como LSTM (HOCHREITER; SCHMIDHUBER, 1997), Transformers (VASWANI et al., 2017), CNNs e Redes Neurais Recorrentes (RNNs, do inglês *Recurrent Neural Networks*) com atenção, têm sido amplamente utilizadas em tarefas de previsão ambiental, demonstrando resultados promissores na modelagem de séries temporais multivariadas (LIU et al., 2019; SITU et al., 2024; SHAN et al., 2023). Além disso, abordagens híbridas que combinam diferentes estruturas — como LSTMs com mecanismos de atenção ou CNNs com camadas recorrentes — vêm se mostrando eficazes na tarefa de previsão de enchentes e vazão de rios, especialmente quando aplicadas a dados captados por sensores ambientais (ZHOU et al., 2021; KILINC et al., 2025).

1.2 Objetivos

1.2.1 Objetivo geral

O objetivo geral deste trabalho é realizar um estudo comparativo de técnicas baseadas em redes neurais para predição de manchas de alagamento em ambientes urbanos sensorizados, com dados reais coletados em pontos críticos da cidade do Rio de Janeiro. A proposta busca investigar o desempenho, a robustez e a aplicabilidade prática de diferentes arquiteturas, visando contribuir para o aprimoramento de sistemas preditivos de suporte à gestão de riscos hidrológicos urbanos. A originalidade deste estudo reside na aplicação dessas técnicas de aprendizado de máquina em dados ambientais locais do Rio de Janeiro, associada à comparação sistemática

entre diferentes modelos para identificar a abordagem mais eficaz neste contexto específico.

1.2.2 Objetivos específicos

Este trabalho tem como objetivos específicos realizar uma revisão sistemática da literatura sobre o uso de redes neurais para previsão de alagamentos urbanos, com ênfase em abordagens recentes aplicadas a dados ambientais; coletar e organizar dados provenientes de sensores ambientais, incluindo informações de chuva, nível da água, vento, pressão atmosférica, dentre outras variáveis, instalados em pontos críticos da cidade do Rio de Janeiro; analisar a influência e o comportamento dessas variáveis, após o processamento, na ocorrência de manchas de alagamento; implementar e treinar diferentes modelos de redes neurais, tais como, CNNs, LSTMs, Redes de Estados Ecoantes (ESNs, do inglês *Echo State Networks*), Redes Neurais de Grafos (GNNs, do inglês *Graph Neural Networks*) e Transformer; avaliar o desempenho das arquiteturas propostas por meio de métricas adequadas, como erro quadrático médio (RMSE, do inglês *Root Mean Square Error*), erro absoluto médio (MAE, do inglês *Mean Absolut Error*) e F1-score, a fim de comparar o desempenho preditivo das diferentes arquiteturas sobre o conjunto de dados reais obtidos pelos sensores ambientais; e, por fim, discutir a aplicabilidade prática e as limitações de cada abordagem, visando identificar aquelas que apresentem maior potencial para apoiar a gestão de riscos hidrológicos urbanos no contexto específico da cidade do Rio de Janeiro.

1.3 Organização do trabalho

Este documento está estruturado em cinco capítulos.

No capítulo 2, é realizada uma breve revisão bibliográfica dos principais assuntos que serão abordados no decorrer do projeto, como os principais conceitos relacionados à predição de manchas de alagamento, com foco em técnicas de aprendizado de máquina, redes neurais artificiais e suas aplicações em problemas ambientais. São discutidas arquiteturas relevantes, como LSTM, redes com atenção e Transformers, além de abordagens recentes que combinam diferentes estruturas neurais para lidar com dados temporais e espaciais de sensores ambientais.

O capítulo 3 descreve a metodologia adotada para o desenvolvimento do estudo, incluindo a coleta e pré-processamento dos dados, o treinamento dos modelos e a análise comparativa dos resultados obtidos, bem como o cronograma previsto para a execução das etapas do

projeto. O capítulo 4 apresenta uma relação de periódicos e eventos científicos com potencial para publicação.

Por fim, o capítulo 5 apresenta os recursos necessários para a realização do projeto.

2 REVISÃO DA LITERATURA

Neste capítulo, apresenta-se a revisão de literatura que fundamenta os principais conceitos e abordagens utilizados ao longo deste trabalho. Inicialmente, na seção 2.1, são discutidos aspectos gerais sobre a predição de alagamentos urbanos, com ênfase no uso de sensores ambientais, dados IoT e modelos baseados em aprendizado de máquina, incluindo redes neurais e arquiteturas híbridas. Em seguida, na seção 2.2, explora-se a modelagem de séries temporais ambientais, abordando a estrutura dos dados, estratégias de pré-processamento e os desafios decorrentes da natureza ruidosa e incompleta das informações coletadas em ambientes reais.

2.1 A predição de alagamentos urbanos: Visão geral e trabalhos correlatos

Segundo Guo, Guan e Yu (2021), Nkwunonwo, Whitworth e Baily (2020) e Li et al. (2025) a intensificação de eventos extremos decorrentes de mudanças climáticas, aliada à urbanização acelerada e muitas vezes desordenada, tem ampliado os riscos associados aos alagamentos urbanos. Essas ocorrências afetam de forma direta a mobilidade, a saúde pública e a segurança de milhões de pessoas em centros urbanos densamente povoados (ZHOU et al., 2023; OKACHA et al., 2024). Nesse contexto, prever com antecedência a formação de manchas de alagamento torna-se uma necessidade estratégica para a gestão urbana inteligente e resiliente (SOARES et al., 2025; GUAN et al., 2024; WANG et al., 2024).

A utilização de sensores ambientais em áreas urbanas — como pluviômetros automáticos, sensores de nível d'água, umidade, pressão atmosférica e velocidade do vento — tem permitido avanços importantes na coleta de dados em tempo real (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023). Esses dispositivos, integrados a sistemas IoT, fornecem uma base de dados rica e contínua para alimentar algoritmos de previsão de alagamentos, com ganhos expressivos em incerteza das estimações e capacidade de resposta (GUAN et al., 2024; SYEED et al., 2022; SOARES et al., 2025). De acordo com Zhang et al. (2022), sistemas sensoriais bem distribuídos espacialmente são capazes de detectar alterações hidrológicas locais com alta sensibilidade, contribuindo significativamente para a predição de eventos críticos em zonas vulneráveis.

Além disso, ambientes urbanos sensorizados favorecem a implementação de sistemas de alerta precoce (*early warning systems*), que integram dados em tempo real a modelos preditivos baseados em inteligência artificial (SOARES et al., 2025; NARAYANA et al., 2024). Essa

abordagem tem sido apontada por estudos recentes como uma das mais promissoras para a redução de impactos socioeconômicos causados por alagamentos (PIADEH; BEHZADIAN; ALANI, 2022; OKACHA et al., 2024). A capacidade de antecipar esses eventos com minutos ou horas de antecedência é determinante para otimizar a mobilização de recursos de emergência e alertar populações em risco (SYEED et al., 2022; WANG et al., 2024).

Portanto, a predição de manchas de alagamentos em ambientes urbanos sensorizados representa um eixo fundamental da transformação digital das cidades. Trata-se de uma aplicação concreta da ciência de dados e da inteligência artificial em benefício direto da população urbana, alinhada aos princípios de sustentabilidade e resiliência urbana defendidos por políticas públicas contemporâneas.

2.1.1 A predição de manchas de alagamentos em ambientes urbanos sensorizados e sua modelagem básica

A predição de manchas de alagamento em ambientes urbanos sensorizados pode ser formalizada como um problema de modelagem de séries temporais multivariadas, no qual os vetores $\mathbf{x}_t \in \mathbb{R}^n$ representam as leituras ambientais coletadas por sensores em um dado instante t , como precipitação, umidade, pressão atmosférica, velocidade do vento e nível de água (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023).

A função preditiva f , treinada sobre dados históricos, tem como objetivo estimar a ocorrência ou não de uma mancha de alagamento futura (ZAKARIA; JABBAR; SULAIMAN, 2023):

$$\hat{y}_{t+k} = f(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-w+1}), \quad (2.1)$$

em que:

- \hat{y}_{t+k} representa a previsão da variável-alvo (por exemplo, nível de lâmina d'água acima de um limiar crítico) para um instante futuro $t + k$, sendo o acento circunflexo indicativo de valor estimado;
- $f(\cdot)$ denota a função preditiva aprendida pelo modelo a partir de dados passados;
- $\mathbf{x}_t \in \mathbb{R}^n$ corresponde ao vetor de variáveis ambientais no instante t , tais como precipitação, nível de água, umidade e pressão atmosférica;

- w é o tamanho da janela de observação, definindo o número de instantes anteriores considerados para a previsão;
- k é o horizonte de previsão, isto é, a quantidade de passos à frente que se deseja prever.

Entre os modelos preditivos mais utilizados para esta tarefa, as redes do tipo *Long Short-Term Memory* (LSTM) destacam-se pela capacidade de capturar dependências de longo prazo, evitando problemas como o *vanishing gradient*, fenômeno no qual, durante a retropropagação, os gradientes ficam tão pequenos ao recuar no tempo (ou em camadas) que a rede não consegue aprender relações entre eventos distantes (BENTIVOGLIO et al., 2022; HOCHREITER; SCHMIDHUBER, 1997). O funcionamento de uma célula LSTM pode ser resumido pela seguinte relação de atualização dos estados (HOCHREITER; SCHMIDHUBER, 1997):

$$\mathbf{h}_t, \mathbf{c}_t = \text{LSTM}(\mathbf{x}_t, \mathbf{h}_{t-1}, \mathbf{c}_{t-1}), \quad (2.2)$$

onde:

- \mathbf{x}_t é o vetor de entrada no instante t ;
- \mathbf{h}_{t-1} é o estado oculto (*hidden state*) no instante anterior, que armazena a memória de curto prazo;
- \mathbf{c}_{t-1} é o estado de célula (*cell state*) no instante anterior, responsável pela memória de longo prazo;
- \mathbf{h}_t é o novo estado oculto, utilizado tanto como saída no instante atual quanto como entrada para o próximo instante;
- \mathbf{c}_t é o novo estado de célula, atualizado a partir de \mathbf{c}_{t-1} e \mathbf{x}_t por meio de mecanismos de portas (*gates*).

Além disso, arquiteturas híbridas como CNN-LSTM, Transformers e GNNs têm demonstrado desempenho promissor ao integrar dimensões espaciais e temporais na previsão de alagamentos localizados (LI et al., 2025; SONG; GUAN; YU, 2025).

De forma complementar e igualmente importante, a distribuição espacial dos sensores permite identificar padrões hidrológicos locais (ZAKARIA; JABBAR; SULAIMAN, 2023; NARAYANA et al., 2024). Em termos práticos, cada ponto de medição fornece, a cada instante, um conjunto de variáveis ambientais (por exemplo, precipitação, nível d'água, umidade e

pressão), além da sua localização geográfica (latitude e longitude) (ZAKARIA; JABBAR; SULAIMAN, 2023; NARAYANA et al., 2024). Em modelos espaço-temporais, essas duas peças de informação — a série temporal de cada sensor e a sua posição no território — são combinadas para que o algoritmo aprenda tanto a dinâmica no tempo quanto a estrutura no espaço (GUAN et al., 2024; SONG; GUAN; YU, 2025). A partir disso, o modelo pode produzir saídas por sensor (como a probabilidade de alagamento em cada ponto monitorado) ou níveis de risco por ponto/área, o que é particularmente útil para mapear *hotspots* e antecipar a propagação de alagamentos (WANG et al., 2024; YU et al., 2023). Arquiteturas híbridas como CNN–LSTM, modelos baseados em atenção e GNNs têm se mostrado eficazes nessa integração de tempo e espaço em ambientes urbanos sensorizados (LI et al., 2025; SONG; GUAN; YU, 2025; GUAN et al., 2024; XU et al., 2024).

A Figura 2.1 abaixo ilustra um exemplo de séries temporais ambientais típicas, obtida em um cenário simulado de monitoramento urbano. Nela, observa-se a evolução de três variáveis críticas — precipitação, nível da água e umidade relativa — ao longo de dois dias, evidenciando como picos de precipitação podem desencadear elevações abruptas nos níveis de água.




Figura 2.1: séries temporais simuladas de precipitação, nível da água e umidade relativa em um ambiente urbano sensorizado (Zakaria, Jabbar e Sulaiman (2023), Narayana et al. (2024)). (Fonte: elaborado pelo autor).

Essa integração entre sensores e modelos de IA viabiliza sistemas com alta capacidade de resposta em tempo real, elevando a precisão e a robustez das previsões (SOARES et al., 2025; SYEED et al., 2022).

Modelos como GNNs são ainda capazes de codificar relações estruturais do espaço urbano, como topografia, malha viária e rede de drenagem, o que eleva a qualidade da previsão espacial (GUAN et al., 2024). Essa abordagem tem potencial para antecipar com precisão os chamados *hotspots* — regiões com maior recorrência ou gravidade de alagamentos.

Outra perspectiva importante é a capacidade adaptativa desses modelos diante de condições ambientais adversas. Ao contrário dos modelos hidrológicos tradicionais, que exigem parametrização e conhecimento explícito do sistema físico (BEVEN, 2011), redes neurais conseguem aprender padrões não lineares diretamente dos dados (AHMED; RIO-CHANONA; MERCANGÖZ, 2023).

Em ambientes urbanos densamente monitorados, os dados de sensores podem ser organizados como uma coleção de tempo-sensores-variáveis (séries temporais multivariadas por ponto de medição) (XU et al., 2024; GUAN et al., 2024). Modelos baseados em atenção, como os Transformers, lidam bem com essa estrutura ao ponderar dinamicamente a relevância de cada sensor e de cada instante, aprendendo padrões espaciais e temporais mesmo em cenários com forte heterogeneidade (por exemplo, áreas baixas, topografia irregular ou infraestrutura precária) (ZHOU et al., 2023; GUAN et al., 2024; SONG; GUAN; YU, 2025).

Para uso operacional, a saída contínua do modelo costuma ser convertida em decisão binária de alagamento/não alagamento por meio de um limiar crítico, o que facilita a integração com sistemas de alerta precoce voltados a autoridades e populações vulneráveis (PIADEH; BEHZADIAN; ALANI, 2022; SOARES et al., 2025). Além disso, as probabilidades estimadas por ponto podem ser apresentadas como mapas de calor e integradas a sistemas de informação geográfica (GIS), apoiando decisões em tempo real (GUAN et al., 2024; CHOI et al., 2025).

Esses elementos — estruturação dos dados, integração espaço-temporal e decisão operacional — fundamentam as etapas apresentadas nas seções seguintes, nas quais detalhamos o pré-processamento (alinhamento temporal, imputação e normalização), a definição de janelas (w) e do horizonte de previsão (k), além de procedimentos de calibração e avaliação que preservam a ordem temporal dos dados (ZAKARIA; JABBAR; SULAIMAN, 2023; NARAYANA et al., 2024; XU et al., 2024; GUAN et al., 2024; SOARES et al., 2025).

2.1.2 O uso de sensores ambientais e dados IoT em contextos urbanos

O uso de sensores ambientais interconectados, viabilizados pela Internet das Coisas, tem transformado a coleta e o uso de dados hidrometeorológicos para previsão e mitigação de alagamentos urbanos (SYEED et al., 2022; SOARES et al., 2025). Sensores distribuídos em áreas críticas medem variáveis como precipitação, umidade do ar, pressão atmosférica, velocidade do vento e nível de lâmina d'água, alimentando continuamente bases de dados em tempo real (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023).

A Figura 2.2 ilustra uma rede urbana de sensores conectados, destacando a infraestrutura distribuída para uma malha de monitoramento ambiental. Do ponto de vista de uma modelagem, essa rede pode ser representada como um *grafo*, no qual os vértices correspondem aos sensores ativos e as arestas indicam enlaces de comunicação ou relações de proximidade/adjacência espacial (ZHANG et al., 2023; LöWE et al., 2021). Uma configuração adequada favorece boa cobertura da malha urbana e transmissão eficiente para plataformas em nuvem, onde ocorre o processamento e a inferência preditiva (GUAN et al., 2024; SOARES et al., 2025).




Figura 2.2: exemplo ilustrativo de sensores IoT distribuídos em um ambiente urbano; conexões indicam links ativos entre sensores com alcance comum (Narayana et al. (2024).
(Fonte: elaborado pelo autor).

Cada sensor fornece sua própria série temporal para uma ou mais variáveis ambientais; em conjunto, essas séries compõem um conjunto multissensorial por instante de tempo. Quando há múltiplas variáveis por sensor, é comum organizar os dados no formato “tempo – sensores – variáveis”, preservando tanto a evolução temporal quanto as diferenças espaciais entre pontos de medição (XU et al., 2024; GUAN et al., 2024). Esse arranjo facilita a utilização de modelos que incorporam localização geográfica (latitude/longitude) e relações de vizinhança, como as redes neurais de grafos (GNNs), que operam diretamente sobre a estrutura do grafo (GUAN et al., 2024).

Com a evolução da computação de borda (*edge computing*), muitos sensores IoT modernos também realizam inferência local, reduzindo latência e aumentando a capacidade de resposta de sistemas de alerta precoce (ZAKARIA; JABBAR; SULAIMAN, 2023; CHOI et al., 2025). Assim, decisões imediatas podem ser tomadas em campo, mesmo antes do processamento centralizado em nuvem (CHOI et al., 2025). Essas capacidades são particularmente críticas em áreas urbanas densas, onde a propagação rápida de alagamentos pode gerar danos severos. Sistemas embarcados descritos por Narayana et al. (2024) e Soares et al. (2025) viabilizam comunicação máquina-a-máquina (M2M), ativando semáforos, barreiras ou enviando alertas diretamente a dispositivos móveis. A qualidade dos dados coletados influencia diretamente a robustez dos modelos preditivos; por isso, estratégias de detecção de falhas, preenchimento de lacunas e padronização/normalização são necessárias para preservar a integridade das entradas dos modelos (SYEED et al., 2022; LI et al., 2025).

De modo geral, redes de sensores IoT não apenas viabilizam a coleta intensiva de dados ambientais, como também sustentam soluções modernas de previsão de alagamentos baseadas em inteligência artificial (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023). Na prática, arquiteturas como CNN-LSTM, Transformers e GNNs permitem estimativas por ponto/área e emissão de alertas quase que em tempo real; a computação de borda reduz a latência e mantém a operação mesmo com conectividade intermitente (CHOI et al., 2025; ZAKARIA; JABBAR; SULAIMAN, 2023). Além disso, a visualização das probabilidades em mapas de risco integrados a GIS facilita a priorização de respostas, enquanto rotinas de qualidade de dados (detecção de falhas, imputação e normalização) e processos de calibração/avaliação que respeitam a ordem temporal aumentam a confiabilidade dos resultados (SYEED et al., 2022; XU et al., 2024; LI et al., 2025).

2.1.3 Modelos baseados em aprendizado de máquina tradicional e as redes neurais profundas

A evolução dos métodos de predição de alagamentos urbanos acompanha o avanço das técnicas de aprendizado de máquina (AM), que podem ser divididas em duas grandes categorias: modelos tradicionais e modelos baseados em redes neurais profundas (*deep learning*). Ambos têm sido amplamente explorados na literatura, cada um apresentando vantagens e limitações específicas no contexto de séries temporais e dados ambientais multivariados.

2.1.3.1 Modelos tradicionais de aprendizado de máquina

Entre os métodos tradicionais, destacam-se algoritmos como Regressão Linear (OLS, do inglês *Ordinary Least Squares*), Regressão logística (do inglês, *Logistic Regression*), Árvore de Decisão (DT, do inglês *Decision Tree*), Floresta Aleatória (RF, do inglês *Random Forest*), Máquina de Vetor de Suporte (SVM, do inglês *Support Vector Machine*) e K-Vizinhos mais próximos (K-NN, do inglês *K-Nearest Neighbors*) (SYEED et al., 2022). Esses modelos são conhecidos por sua simplicidade, interpretabilidade e menor demanda computacional, sendo utilizados principalmente em cenários com conjuntos de dados menores ou quando a explicabilidade do modelo é uma prioridade (MOSAVI; OZTURK; CHAU, 2018).

No contexto de alagamentos urbanos, RF e SVM são modelos discriminativos sem dinâmica interna; por isso, são mais adequados a mapeamentos estáticos — por exemplo, classificação de suscetibilidade/áreas de risco — e a previsões de curto prazo *quando* a informação temporal é codificada explicitamente no vetor de atributos (defasagens, janelas deslizantes, estatísticas móveis) (SYEED et al., 2022; MOSAVI; OZTURK; CHAU, 2018). Esses cenários, costumam apresentar bom desempenho com dados tabulares bem estruturados; já a captura de dependências temporais de longo alcance tende a requerer arquiteturas sequenciais como LSTM, LSTM com atenção, TCN, Transformers e etc. (SYEED et al., 2022; ZHANG et al., 2022).

Contudo, como discutido por Syeed et al. (2022), Eskandarian et al. (2022), Mosavi, Ozturk e Chau (2018), modelos tradicionais como, RF, SVM, k-NN e DT são essencialmente mapeamentos estáticos, sem estado interno, pois quando aplicados a séries temporais, dependem de uma engenharia de atributos para incorporar informação dinâmica, e por isso tendem a apresentar limitações diante de relações temporais complexas, alta dimensionalidade e não linearidades típicas de séries ambientais. Ainda assim, esses modelos são amplamente empregados

como alternativas pragmáticas aos métodos estatísticos clássicos e hidrológicos em contextos urbanos, especialmente para classificação de suscetibilidade e previsões de curto prazo com dados tabulares multivariados e bem estruturados (MOSAVI; OZTURK; CHAU, 2018; SYEED et al., 2022).

A seguir, considerando uma abordagem mais explicativa, destacam-se alguns dos principais algoritmos tradicionais utilizados na literatura para a predição de manchas de alagamentos urbanos:

Regressão Linear: um modelo paramétrico simples e interpretável que assume relação linear entre variáveis de entrada e a saída (SYEED et al., 2022; MOSAVI; OZTURK; CHAU, 2018). É frequentemente usado como *baseline* e para análise de sensibilidade/efeito de variáveis (YU et al., 2023; SOARES et al., 2025). Por não possuir dinâmica interna, em séries temporais depende de engenharia de atributos (defasagens, janelas deslizantes, agregações) para representar a informação temporal; é sensível à dependência linear entre os preditores e à não estacionariedade, mas tende a funcionar bem quando as relações são aproximadamente lineares e os dados estão bem condicionados (MOSAVI; OZTURK; CHAU, 2018; SYEED et al., 2022).

Regressão Logística: a regressão logística é frequentemente utilizada para estimar a probabilidade de ocorrência de eventos binários, como a presença ou ausência de alagamento em determinado local (SOARES et al., 2025). Sua simplicidade e capacidade de fornecer resultados facilmente interpretáveis a tornam útil como *baseline* em estudos comparativos (SYEED et al., 2022; MOSAVI; OZTURK; CHAU, 2018).

Árvores de Decisão: as DT são modelos baseados em regras para particionar o espaço de dados, facilitando a identificação de padrões e a interpretação dos resultados (MOSAVI; OZTURK; CHAU, 2018). São empregadas para identificar fatores críticos para a ocorrência de alagamentos e servem de base para métodos ensemble como o Random Forest (SOARES et al., 2025).

Floresta Aleatória: o Random Forest é um método de ensemble baseado em múltiplas árvores de decisão, reconhecido por sua robustez a ruídos, capacidade de lidar com dados multivariados e por fornecer informações interpretáveis sobre a importância das variáveis (MOSAVI; OZTURK; CHAU, 2018; SYEED et al., 2022; ZHANG et al., 2022). Tem sido amplamente utilizado para classificação de áreas de risco de alagamento e previsão de variáveis hidrológicas em ambientes urbanos, apresentando resultados consistentes mesmo em cenários com dados heterogêneos e não lineares (YU et al., 2023).

Máquina de vetor de suporte: o SVM é um algoritmo eficiente para tarefas de classificação e regressão, especialmente em contextos de alta dimensionalidade e conjuntos de dados menores (SYEED et al., 2022). Sua capacidade de encontrar hiperplanos ótimos de separação entre classes, mesmo em problemas não linearmente separáveis, torna-o relevante para distinguir situações de risco de alagamento em ambientes urbanos sensorizados (MOSAVI; OZTURK; CHAU, 2018).

k-Vizinhos mais próximos: o k-NN é um método baseado em instâncias, que classifica ou prediz valores a partir da similaridade com vizinhos mais próximos no conjunto de dados (MOSAVI; OZTURK; CHAU, 2018). Embora simples e intuitivo, seu desempenho pode ser afetado por grandes volumes de dados ou ruídos, sendo mais indicado para conjuntos de dados menores e bem comportados (ESKANDARIAN et al., 2022).

De modo geral, os modelos tradicionais de aprendizado de máquina oferecem vantagens como facilidade de implementação, interpretabilidade e menor dependência de grandes volumes de dados rotulados. Entretanto, apresentam limitações ao lidar com relações temporais e espaciais complexas, não linearidades acentuadas e grandes conjuntos de dados multivariados, contextos nos quais as redes neurais profundas tendem a se destacar (MOSAVI; OZTURK; CHAU, 2018; SYEED et al., 2022; SOARES et al., 2025).

2.1.3.2 Redes neurais profundas

O surgimento das redes neurais profundas (DNNs, do inglês *Deep Neural Networks*) revolucionou a modelagem de fenômenos ambientais ao permitir o processamento de grandes volumes de dados e a extração automática de padrões complexos (BENTIVOGLIO et al., 2022; ZHOU et al., 2023). Em contextos urbanos sensorizados, essas arquiteturas conseguem incorporar simultaneamente a heterogeneidade espacial (diferenças entre pontos de medição) e a dinâmica temporal (variações horárias e diárias), aprendendo relações não lineares e de longo alcance entre múltiplas variáveis meteorológicas e hidrológicas (XU et al., 2024; LI et al., 2025). Na prática, diferentes famílias se complementam: CNNs capturam padrões locais e geram representações úteis para mapas de risco; LSTM/GRU (GRU, do inglês *Gated Recurrent Unit*) modelam dependências temporais prolongadas; Transformers, via mecanismos de atenção, ampliam o alcance temporal e facilitam o paralelismo; e as GNNs que codificam explicitamente a vizinhança espacial dos sensores e a conectividade do sistema de drenagem urbana (SONG; GUAN; YU, 2025; CHOI et al., 2025; ZHANG et al., 2023). Além do ganho

preditivo, tais modelos têm se mostrado mais resilientes a ruído, dados faltantes e escalas distintas entre variáveis, especialmente quando combinados em arquiteturas híbridas (CNN–LSTM, CNN–Transformer) (XU et al., 2024; SONG; GUAN; YU, 2025).

Neste trabalho, serão exploradas tais arquiteturas com dados de sensores ambientais para avaliar a robustez da predição durante eventos hidrológicos extremos, cenário no qual a modelagem precisa lidar com picos abruptos, defasagens variáveis e mudanças rápidas nas condições locais (LI et al., 2025; CHOI et al., 2025). Entre as arquiteturas mais relevantes para a predição de alagamentos urbanos, destacam-se:

Perceptron Multicamada (MLP, do inglês *Multilayer Perceptron*): utilizado como *baseline* em muitos estudos, o MLP pode capturar relações não lineares entre variáveis ambientais, mas não é ideal para sequências temporais devido à ausência de memória interna (BENTIVOGLIO et al., 2022).

Redes Neurais Recorrentes: as RNNs, especialmente as LSTM, são projetadas para modelar dependências temporais de longo prazo, tornando-se referência em tarefas de previsão hidrológica e de séries temporais ambientais (HOCHREITER; SCHMIDHUBER, 1997; LIU et al., 2019). Estudos recentes demonstram que LSTMs superam modelos tradicionais em acurácia ao prever níveis de água e identificar padrões de alagamento em dados multivariados (SITU et al., 2024).

Redes Neurais Convolucionais: embora originalmente desenvolvidas para processamento de imagens, as CNNs vêm sendo adaptadas para séries temporais e dados espaciais, destacando-se na detecção de padrões locais e na análise de mapas de risco de alagamento (ZHOU et al., 2021). Em ambientes urbanos, CNNs são eficazes na integração de dados de sensores distribuídos espacialmente, extraindo características relevantes para a previsão de eventos extremos (ZHOU et al., 2023; GUAN et al., 2024)

Modelos híbridos CNN–LSTM e ConvLSTM: Esses modelos combinam “padrões locais” (CNN) com dependências temporais (LSTM) ou usam convoluções dentro da célula recorrente (ConvLSTM) para capturar espaço+tempo de forma conjunta. São amplamente reportados com bom desempenho em previsão espaço-temporal de alagamentos (ZHOU et al., 2023; SITU et al., 2024; SONG; GUAN; YU, 2025).

Transformers: os modelos baseados em atenção, como o Transformer, têm ganhado espaço devido à sua capacidade de capturar dependências de longo alcance em séries temporais mul-

tivariadas, além de facilitarem o paralelismo no treinamento (VASWANI et al., 2017; CHOI et al., 2025). Recentemente, Transformers foram aplicados com sucesso na previsão de chuvas intensas e enchentes, superando LSTMs em cenários com grandes volumes de dados e múltiplas variáveis (CAO et al., 2025). Além disso variantes como, Informer, transformer de fusão temporal (TFT, do inglês *Temporal Fusion Transformer*) e Transformer de janelas deslocadas (Swin, do inglês *Swin Transformer*) têm sido aplicadas a chuvas intensas e mapas de inundação, superando LSTM em cenários com muitos dados/variáveis (VASWANI et al., 2017; CHOI et al., 2025; CAO et al., 2025).

Redes Neurais de Grafos: as GNNs são especialmente adequadas para modelar relações espaciais complexas, como a conectividade entre sensores ambientais em diferentes regiões urbanas. Na prática, cada sensor é um *nó* e as conexões (*arestas*) podem refletir proximidade geográfica, conectividade do sistema de drenagem urbana (galerias/canais) ou vias com escoamento preferencial (ZHANG et al., 2023; LöWE et al., 2021). As GNNs propagam informação ao longo desse grafo (mensagens entre nós), permitindo que o modelo aprenda como sinais de chuva/nível “viajam” no espaço urbano, além de integrar atributos locais do sensor (séries temporais, altitude, uso do solo) (ZHANG et al., 2023; LöWE et al., 2021; GUAN et al., 2024).

2.1.3.3 Comparativo e tendências

De modo geral, redes neurais profundas apresentam desempenho superior ao de modelos tradicionais na predição de alagamentos urbanos, principalmente em ambientes com dados volumosos, não lineares e multivariados (BENTIVOGLIO et al., 2022). No entanto, modelos tradicionais ainda são relevantes em aplicações nas quais a interpretabilidade, a robustez frente a pequenos conjuntos de dados e o baixo custo computacional são essenciais (ZAKARIA; JABBAR; SULAIMAN, 2023).

A literatura recente aponta para uma tendência de integração entre diferentes arquiteturas, combinando as vantagens de cada abordagem para lidar com os desafios específicos dos dados ambientais urbanos (SONG; GUAN; YU, 2025). Assim, a escolha do modelo mais adequado depende do contexto, das características dos dados disponíveis e dos objetivos práticos da aplicação (OKACHA et al., 2024). A Figura 2.3 apresenta uma linha do tempo que sintetiza a evolução dos modelos tradicionais e das redes neurais profundas, bem como tendências recentes, com foco na predição de manchas de alagamento urbano.

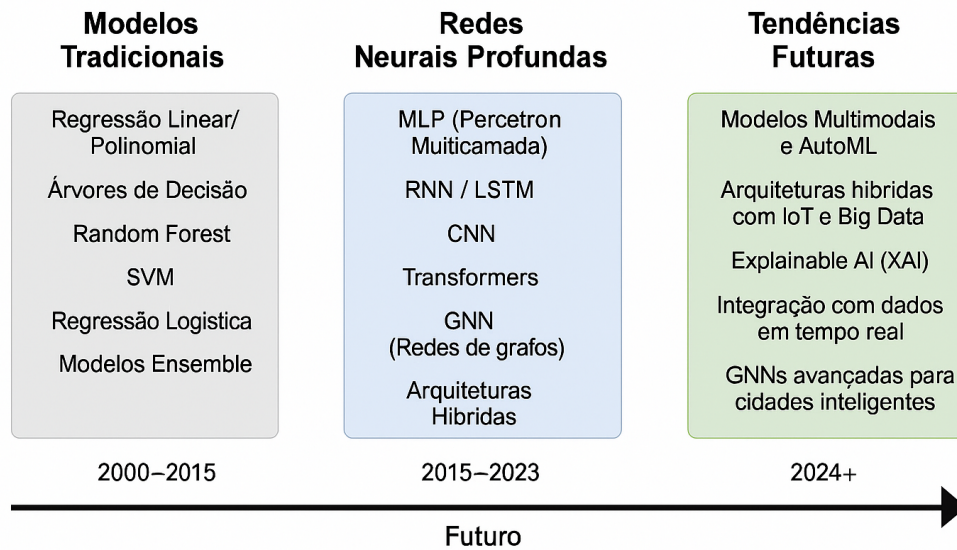


Figura 2.3: linha do tempo e a evolução dos modelos de aprendizado de máquina para a predição de manchas de alagamentos urbanos (Vaswani et al. (2017), Zhang et al. (2022)) . (Fonte: elaborado pelo autor).

2.1.4 Arquiteturas híbridas e tendências recentes

Nos últimos anos, observa-se um uso crescente de **arquiteturas híbridas** na predição de manchas de alagamento urbano, sobretudo em cenários com alta dimensionalidade de dados ambientais, dependências temporais complexas e heterogeneidade espacial (SONG; GUAN; YU, 2025). Essas arquiteturas combinam paradigmas de aprendizado profundo — convoluções, recorrência e atenção — para contornar limitações de modelos isolados e ampliar o desempenho preditivo (CAO et al., 2025).

Uma estratégia recorrente é a fusão entre redes convolucionais e redes recorrentes do tipo LSTM. Nessa combinação, as CNNs extraem padrões locais (no espaço ou no tempo) e as LSTMs modelam as dependências temporais de médio e longo alcance (ZHOU et al., 2023; SITU et al., 2024). Variantes como *ConvLSTM* incorporam a convolução *dentro* da célula recorrente, tratando espaço e tempo de forma conjunta e mostrando bons resultados em dados multissensores de ambientes urbanos, tanto em variabilidade sazonal quanto em eventos extremos (SITU et al., 2024).

Modelos recentes estendem essa ideia com componentes de atenção. O *SwinFlood*,

por exemplo, integra CNNs com *Swin Transformers* — uma variante hierárquica com janelas deslocadas — favorecendo a representação de dados estruturados em malhas urbanas (SONG; GUAN; YU, 2025). De modo semelhante, a *U-RNN* combina módulos recorrentes com codificadores espaciais de alta resolução, aprimorando a previsão em regiões densamente sensoriizadas (CAO et al., 2025). Essa convergência de técnicas especializadas reflete uma tendência consolidada na literatura (SHAN et al., 2023): CNNs para características locais; LSTM/GRU para dinâmica temporal; e mecanismos de atenção (oriundos dos Transformers) para ponderar, de forma adaptativa, a relevância contextual do histórico — aspecto crucial em séries irregulares (KOYA; ROY, 2024).

Arquiteturas como o **Temporal Fusion Transformer (TFT)** também vêm ganhando espaço em séries temporais multivariadas por aliarem atenção com seleção de variáveis e blocos de *gating*, oferecendo interpretações sobre variáveis sazonais e exógenas (SHAN et al., 2023). Paralelamente, a integração com dados multimodais e a adoção de *edge computing* permitem operação em tempo quase real mesmo sob restrições de conectividade e processamento (NARAYANA et al., 2024). Estudos recentes destacam ainda a importância de modelos enxutos e responsivos para sistemas de alerta precoce em zonas urbanas críticas (CHOI et al., 2025; SOARES et al., 2025).

Por fim, cresce gradualmente o interesse por **IA explicável (XAI, do inglês *Explainable AI*)**, visando transparência e confiança em aplicações de interesse público aonde técnicas de explicação ajudam gestores a compreender e justificar decisões com base em evidências extraídas dos próprios modelos híbridos (GONG; LI; WANG, 2022). Como apoio visual, a Figura 2.4 sintetiza exemplos de arquiteturas híbridas (p. ex., CNN–LSTM com atenção, GNN–LSTM–CNN e U-RNN com codificação espaço-temporal) e suas camadas, aplicadas à previsão de alagamentos urbanos.

No presente trabalho, utilizaremos essas diretrizes para selecionar combinações viáveis e avaliá-las em dados de sensores ambientais, com foco em robustez durante eventos de chuva intensa. As etapas de preparação dos dados, definição de janelas temporais (w) e horizonte de previsão (k), além dos procedimentos de calibração e avaliação preservando a ordem temporal, serão detalhadas adiante. Serão considerados ainda cenários de dados faltantes e leituras ruidosas, analisando a sensibilidade do desempenho a diferentes tamanhos de janela e *lead times*. Para garantir comparabilidade, adotaremos particionamento temporal estrito (treino/validação/-teste) e métricas adequadas à tarefa.

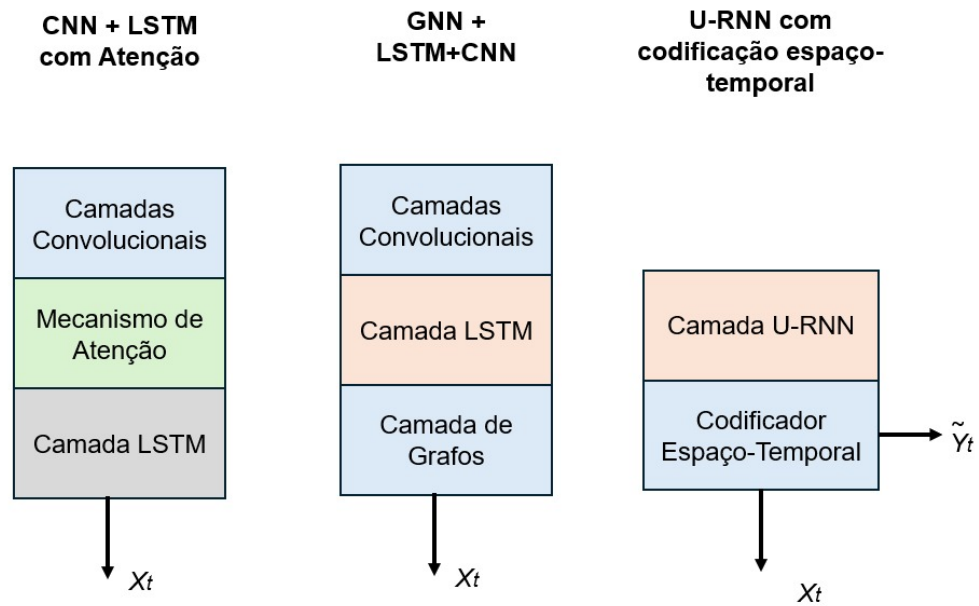


Figura 2.4: exemplos de arquiteturas híbridas aplicadas à previsão de alagamentos urbanos (Song, Guan e Yu (2025), Cao et al. (2025)).
(Fonte: elaborado pelo autor)

2.1.5 Trabalhos recentes e o uso de redes neurais para a previsão de manchas de alagamentos urbanos

Diversos estudos recentes têm demonstrado o potencial das redes neurais profundas na previsão de alagamentos urbanos, em especial na geração de mapas de risco, previsão em tempo real e suporte à decisão para sistemas de alerta precoce (BENTIVOGLIO et al., 2022). Tais estudos se beneficiam do aumento da disponibilidade de dados sensoriais urbanos e da evolução de arquiteturas neurais mais robustas e adaptadas a séries temporais e dados espaciais (CHOI et al., 2025).

No trabalho de Situ et al. (2024), por exemplo, foi proposto um modelo baseado em *LSTM-DeepLabv3+* combinado com otimização bayesiana e fusão de características espaço-temporais. O modelo se mostrou eficaz na previsão da localização de pontos de alagamento urbano, superando abordagens convencionais em métricas como RMSE e F1-score. Essa proposta ilustra a integração entre modelagem temporal profunda e segmentação espacial com convoluções profundas.

Outro destaque é o estudo de Song, Guan e Yu (2025), que desenvolveu o modelo híbrido *SwinFlood*, integrando CNNs com *Swin Transformers*. A abordagem, aplicada a simulações ur-

banas em alta resolução, obteve bons resultados em tarefas de previsão dinâmica de inundações em zonas críticas de drenagem, demonstrando a eficácia dos mecanismos de atenção hierárquica para modelagem multiescala.

Cao et al. (2025), propuseram o modelo *U-RNN*, que utiliza codificadores convolucionais e módulos recorrentes para realizar previsão espaço-temporal com maior resolução. Este modelo foi testado em malhas urbanas sensorizadas, com grande quantidade de variáveis ambientais (chuva, umidade, pressão e vento), e apresentou desempenho superior a LSTM e CNN puras.

Além das arquiteturas híbridas, estudos como o de SOARES et al., 2025 propuseram *frameworks* completos de previsão de enchentes relâmpago baseados em aprendizado de máquina. O modelo *ML4FF*, aplicado a uma bacia hidrográfica no Brasil, combinou redes neurais e dados locais com séries pluviométricas e mostrou bom desempenho mesmo sob restrições computacionais, ilustrando o potencial da aplicação prática em cenários brasileiros.

A incorporação de estruturas gráficas tem sido outro ponto de destaque. Em Guan et al. (2024), os autores propõem o modelo *STFS-Urban*, que realiza simulações de inundação urbana utilizando modelagem espaço-temporal sobre malhas de sensores. A abordagem emprega convoluções espaciais e temporais sobre grafos, o que a torna especialmente eficaz para sistemas de sensores heterogêneos distribuídos.

Por fim, trabalhos como Choi et al. (2025), e Zhang et al. (2022), abordam a necessidade de generalização e capacidade adaptativa em modelos de predição de alagamentos, salientando que arquiteturas, como Transformers com atenção, oferecem melhores condições para o uso institucional desses sistemas.

Com base nesses estudos, observa-se um avanço significativo tanto no desempenho preditivo quanto na capacidade de adaptação dos modelos baseados em redes neurais.

2.1.6 Lacunas e oportunidades na literatura existente

Embora avanços significativos tenham sido observados na aplicação de redes neurais para predição de alagamentos urbanos, a literatura atual ainda apresenta lacunas importantes que limitam o desempenho e a aplicabilidade prática desses modelos em contextos reais (GUO; GUAN; YU, 2021).

Em primeiro lugar, muitos estudos concentram-se em cenários experimentais ou datasets limitados. Por exemplo, abordagens como *LSTM-DeepLabv3+* de Situ et al. (2024) e

SwinFlood de Song, Guan e Yu (2025), embora altamente promissoras, foram avaliadas em regiões específicas e com conjuntos de dados com baixa variabilidade climática e urbana. Isso compromete a generalização dos modelos, como também discutido por Zhang et al. (2022), que destacam a dificuldade de adaptação dos modelos para bacias não monitoradas.

Outra lacuna recorrente é a ausência de abordagens realmente robustas à incompletude dos dados sensoriais (LIU et al., 2019). A maior parte dos trabalhos parte da suposição de que os dados são limpos e completos, o que raramente ocorre em aplicações reais com sensores IoT (ZAKARIA; JABBAR; SULAIMAN, 2023; NARAYANA et al., 2024). A ausência de técnicas sistemáticas de imputação de dados, tratamento de ruídos e análise de sensibilidade limita a aplicabilidade em tempo real.

Do ponto de vista de arquiteturas, embora a combinação entre CNNs, LSTMs e Transformers tenha se mostrado eficaz, ainda há pouca investigação sobre a explicabilidade desses modelos, um aspecto crucial em contextos urbanos decisórios, como destacado em Soares et al. (2025) e Cao et al. (2025). Vale também destacar que as abordagens XAI são promissoras, mas ainda subutilizadas no campo da previsão de alagamentos (GONG; LI; WANG, 2022).

Outro ponto de atenção é a escassez de estudos que avaliem simultaneamente a performance preditiva e os requisitos computacionais em cenários operacionais. Conforme mencionado por Choi et al. (2025), muitos modelos apresentam alta acurácia, mas ainda não são aplicáveis em arquiteturas embarcadas de baixo custo — realidade comum em cidades brasileiras de médio porte.

Além disso, a integração de dados multiespectrais, imagens de radar, ou variáveis de redes sociais urbanas (como dados de mobilidade) ainda é incipiente, apesar de seu potencial complementar (LI et al., 2025). Bentivoglio et al. (2022) e Li et al. (2025) sugerem ainda a fusão de dados heterogêneos como uma fronteira promissora.

Por fim, a carência de bases de dados padronizadas e abertas impede comparações robustas entre diferentes métodos (PIADEH; BEHZADIAN; ALANI, 2022). Apesar de iniciativas como Wang et al. (2024) e Guan et al. (2024), há uma forte dependência de bases de dados próprias, com critérios de avaliação muitas vezes não replicáveis.

Diante dessas lacunas, emergem diversas oportunidades de pesquisa, tais como:

- desenvolvimento de modelos mais robustos à incompletude e ruído em dados reais;
- exploração de arquiteturas híbridas com foco em interpretabilidade (XAI);

- criação de *frameworks* otimizados para dispositivos com restrições computacionais;
- integração de fontes de dados alternativas (drones, redes sociais, sensores de tráfego);
- proposição de protocolos de validação e reprodutibilidade em séries temporais ambientais.

Embora essas direções abram caminhos relevantes para a evolução da área, este trabalho concentra-se em avaliar comparativamente diferentes arquiteturas clássicas de redes neurais, aplicadas a séries temporais ambientais de sensores reais. Dessa forma, busca-se contribuir de forma pragmática para a robustez e aplicabilidade desses modelos em contextos urbanos sensorizados, mantendo o foco na comparação de arquiteturas clássicas, enquanto aspectos como interpretabilidade via XAI ou otimizações embarcadas são reconhecidos como caminhos complementares a serem explorados em investigações posteriores.

2.2 A modelagem de séries temporais ambientais para a predição de alagamentos

A literatura analisada no item 2.1 evidenciou a relevância da predição de manchas de alagamentos urbanos em cenários cada vez mais impactados por eventos de alagamentos extremos. Observou-se que os dados coletados por sensores IoT em ambientes urbanos são fundamentais para capturar a dinâmica hidrológica local, e que os avanços recentes em aprendizado de máquina e redes neurais profundas têm potencial significativo para aprimorar a acurácia e a robustez das previsões (GUO; GUAN; YU, 2021; LEI et al., 2021). Trabalhos correlatos ainda destacam o uso de arquiteturas híbridas e técnicas emergentes, mas também revelam lacunas importantes, como a dificuldade de lidar com séries temporais ambientais de alta complexidade e a escassez de abordagens comparativas sistemáticas.

Além disso, há uma forte interação espacial entre as variáveis observadas, principalmente quando se considera a propagação do alagamento entre diferentes pontos da cidade (CAO et al., 2025; SOARES et al., 2025; FENG et al., 2024). Para lidar com tais desafios, diferentes estratégias têm sido empregadas, incluindo a estruturação adequada das séries temporais, técnicas de janelamento, normalização, redução de dimensionalidade e modelagem com arquiteturas neurais adaptadas (LI et al., 2025; ZHOU et al., 2023). O sucesso da etapa preditiva depende diretamente dessas decisões iniciais de modelagem, que influenciam desde a extração de padrões até a capacidade do modelo de generalizar para novas situações (ZHOU et al., 2023; XU et al., 2024; SONG; GUAN; YU, 2025).

Nesse contexto, a seção 2.2 aprofunda a discussão sobre a modelagem de séries temporais ambientais, etapa essencial para a predição de alagamentos. Diferentemente da visão geral apresentada anteriormente, aqui o foco recai sobre os fundamentos que estruturam essas séries e os desafios matemáticos e computacionais envolvidos em sua manipulação. Serão abordadas as propriedades intrínsecas de séries multivariadas, estratégias de janelamento e normalização, bem como as dificuldades práticas associadas a dados reais, tais como ruído, sazonalidade e valores ausentes (ESKANDARIAN et al., 2022; ZHOU et al., 2023). Essa análise cria a base necessária para compreender como diferentes arquiteturas de redes neurais podem ser aplicadas de forma mais eficiente na tarefa de predição de manchas de alagamentos urbanos.

2.2.1 Estrutura e propriedades de séries ambientais multivariadas

A previsão de manchas de alagamento urbano com base em aprendizado de máquina e redes neurais depende, de forma central, do correto entendimento da estrutura das séries temporais ambientais envolvidas (ZHANG et al., 2022; SONG; GUAN; YU, 2025). Essas séries representam medições contínuas de variáveis como precipitação, nível da água, velocidade do vento, umidade, pressão atmosférica e temperatura, captadas por sensores distribuídos em áreas urbanas. Tais dados são, em sua maioria, multivariados, altamente correlacionados e apresentam variações sazonais, ruído, tendências de longo prazo e forte dependência temporal (LEI et al., 2021; ZAKARIA; JABBAR; SULAIMAN, 2023; CAO et al., 2025).

Do ponto de vista formal, uma série temporal ambiental multivariada pode ser representada como uma sequência de vetores $\mathbf{x}_t \in \mathbb{R}^n$ ao longo do tempo:

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}, \quad \mathbf{x}_t \in \mathbb{R}^n, \quad (2.3)$$

onde:

- \mathbf{X} é a série temporal multivariada completa, composta pelos vetores de observações \mathbf{x}_t ;
- T é o número total de instantes de tempo (tamanho da série);
- n é o número de variáveis ambientais monitoradas (ex.: chuva, nível da água, vento);
- \mathbf{x}_t é o vetor de observação no tempo t .

A modelagem eficaz dessas séries exige considerar algumas de suas principais propriedades:

- *Autocorrelação temporal*: os valores de uma variável em um instante de tempo dependem fortemente de seus próprios valores passados. Tal propriedade é particularmente relevante em séries de nível de água, nas quais há inércia hidrológica (SOARES et al., 2025).
- *Correlações cruzadas*: diferentes variáveis ambientais tendem a estar interligadas. Por exemplo, fortes precipitações estão frequentemente associadas a picos de umidade e elevação da lâmina d'água (GUO; GUAN; YU, 2021).
- *Estacionalidade e tendências*: padrões sazonais recorrentes e tendências de longo prazo são comuns. Essas características podem prejudicar a capacidade preditiva de modelos não adaptados (LEI et al., 2021; XU et al., 2021).
- *Heterogeneidade espacial*: a dinâmica de alagamentos pode variar em diferentes pontos da cidade, exigindo a integração de variáveis georreferenciadas e a incorporação de características espaciais na modelagem (CHOI et al., 2025; FENG et al., 2024).

Com o avanço dos sensores urbanos e do IoT, o volume e a variedade dos dados ambientais têm crescido de forma significativa, tornando os modelos preditivos cada vez mais dependentes da habilidade em manipular estruturas complexas de séries multivariadas (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023).

Além disso, arquiteturas modernas de redes neurais como LSTM, GRU, CNN e Transformers são projetadas justamente para capturar tais padrões multivariados e hierárquicos, exigindo uma representação sólida e bem estruturada das séries de entrada (ZHOU et al., 2023; SONG; GUAN; YU, 2025; ZHANG et al., 2023).

Para que essas arquiteturas sejam eficazes, torna-se essencial a aplicação de estratégias de pré-processamento e engenharia de atributos que favoreçam a extração de relações temporais e espaciais relevantes (ZHOU et al., 2023; XU et al., 2024). Técnicas como janelamento temporal, diferenciação, decomposição de séries e extração de estatísticas descritivas permitem enriquecer a representação dos dados e facilitar o aprendizado de padrões complexos pelos modelos preditivos (LI et al., 2025; ESKANDARIAN et al., 2022). A qualidade dessas etapas influencia diretamente a capacidade do modelo em generalizar, especialmente diante de eventos raros ou extremos, como alagamentos pontuais e súbitos em regiões urbanas densamente sensorizadas (ZHOU et al., 2023; LI et al., 2025).

Adicionalmente, a robustez do modelo frente a ruídos, dados ausentes e variações abruptas depende não apenas da arquitetura utilizada, mas também da qualidade da modelagem inicial

das séries temporais. Assim, a integração entre conhecimento de domínio, sensoriamento ambiental e técnicas de aprendizado profundo torna-se uma peça-chave para o sucesso na predição de manchas de alagamento (CAO et al., 2025; SITU et al., 2024). Esse cenário exige abordagens interdisciplinares e adaptativas, capazes de lidar com os desafios impostos pela variabilidade climática, urbanização desordenada e limitações inerentes aos dados coletados em tempo real (CAO et al., 2025; SONG; GUAN; YU, 2025).




Figura 2.5: exemplo de séries temporais ambientais multivariadas monitoradas por sensores urbanos (chuva, umidade, pressão e nível da água) (Guo, Guan e Yu (2021), Zakaria, Jabbar e Sulaiman (2023)).

(Fonte: elaborado pelo autor)

A figura 2.5 acima ilustra o comportamento conjunto de diferentes variáveis ambientais ao longo do tempo, evidenciando padrões sincronizados, defasagens entre variáveis e possíveis sinais de alerta antecipado para episódios de alagamento — especialmente importantes para

alimentar algoritmos de predição robustos.

2.2.2 Estratégias de janelamento, normalização e modelagem

A modelagem de séries temporais ambientais para predição de alagamentos requer uma preparação rigorosa dos dados de entrada. Isso envolve etapas críticas como o particionamento temporal (janelamento), a normalização estatística das variáveis e a definição da estrutura de entrada/saída para os modelos (FENG et al., 2024; SITU et al., 2024). A efetividade dos algoritmos preditivos, especialmente os baseados em redes neurais, depende diretamente dessas decisões iniciais (ZHOU et al., 2023; CAO et al., 2025).

Janelamento temporal

O janelamento (*windowing*) é uma técnica essencial para transformar uma série temporal contínua em uma sequência de vetores de entrada (*input sequences*) e seus respectivos alvos (*targets*). Considere a série multivariada, $\mathbf{X} = \{\mathbf{x}_t\}_{t=1}^T$, com $\mathbf{x}_t \in \mathbb{R}^n$ representando o vetor de observações das n variáveis em um instante t . Define-se uma janela de tamanho w , que gera:

$$\mathbf{X}_t = [\mathbf{x}_{t-w+1}, \mathbf{x}_{t-w+2}, \dots, \mathbf{x}_t] \in \mathbb{R}^{w \times n}, \quad (2.4)$$

$$\mathbf{y}_t = \mathbf{x}_{t+k}, \quad (2.5)$$

onde \mathbf{y}_t é a variável-alvo associada à janela \mathbf{X}_t , correspondente ao vetor de observações no instante $t+k$, e k representa o horizonte de predição (por exemplo, previsão para 30 minutos ou 1 hora no futuro). A escolha adequada de w e k é sensível ao tipo de fenômeno sendo modelado. Para alagamentos urbanos, estudos recentes sugerem janelas entre 3h e 6h como eficazes para capturar o início de eventos extremos (SITU et al., 2024; SHAN et al., 2023).

Essa abordagem é especialmente importante para arquiteturas como LSTM e Transformers, que operam com sequências de entrada para detectar padrões temporais complexos. Janelas muito pequenas podem resultar em perda de contexto, enquanto janelas excessivamente longas aumentam a dimensionalidade e podem induzir *overfitting* (KOYA; ROY, 2024).

Normalização e padronização

O pré-processamento dos dados também exige técnicas de normalização ou padronização. Como os sensores ambientais monitoram variáveis com diferentes escalas (ex: precipitação em mm, pressão em hPa, umidade em %), é necessário transformá-las para uma faixa comparável, de forma a estabilizar o treinamento dos modelos neurais (AHMED; RIO-CHANONA; MERCANGÖZ, 2023; WANG et al., 2024). As abordagens mais comuns são:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \in [0, 1], \quad (2.6)$$

conhecida como normalização *min-max*, que transforma os valores da variável para uma faixa fixa entre 0 e 1, preservando a proporcionalidade entre as observações.

$$x' = \frac{x - \mu}{\sigma}, \quad (2.7)$$

conhecida como padronização *z-score*, na qual os dados são reescalados para média zero e variância unitária, sendo μ e σ a média e o desvio padrão da variável, respectivamente.

onde:

- x é o valor original da variável ambiental,
- x_{\min} e x_{\max} são, respectivamente, os valores mínimo e máximo observados para a variável,
- x' é o valor transformado após a normalização,
- μ e σ correspondem à média e ao desvio padrão da variável.

A padronização *z-score* é amplamente utilizada para modelos com camadas densas (MLPs, LSTM), enquanto a *min-max* é preferida quando se deseja manter a interpretação física das variáveis (WANG et al., 2024; YU et al., 2023).

Para séries temporais não estacionárias, é recomendado aplicar a normalização com base apenas nos dados de treinamento, evitando vazamento de informação (*data leakage*) para as etapas de validação e teste (YU et al., 2023). Adicionalmente, pode-se realizar a normalização por estação ou hora do dia, compensando padrões sazonais e diurnos, como feito por Cao et al. (2025).

Modelagem e estruturação da entrada

Além de janelas multivariadas, a estrutura de entrada pode ser enriquecida com metainformações (ex: horário, dia da semana, localização geográfica do sensor) (CHOI et al., 2025; SONG; GUAN; YU, 2025).

Em arquiteturas como GNNs e Transformers espaciais, os dados são organizados como tensores

$$\mathcal{X} \in \mathbb{R}^{T \times S \times V}, \quad (2.8)$$

onde:

- \mathcal{X} : tensor espaço-temporal de entrada,
- T : número total de instantes de tempo (tamanho da série),
- S : número de sensores,
- V : número de variáveis medidas por sensor.

O número total de variáveis monitoradas pode ser obtido como $n = S \times V$. Essa estrutura em tensor permite capturar tanto padrões espaciais quanto temporais, algo fundamental para fenômenos como alagamentos urbanos que se propagam espacialmente (GUAN et al., 2024; CHOI et al., 2025).

Arquiteturas híbridas, como CNN-LSTM ou U-RNN, exploram essas estruturas combinando convoluções temporais com codificadores sequenciais e mecanismos de atenção (CAO et al., 2025). Nesses casos, a etapa de modelagem se apoia em convoluções 1D ou 2D aplicadas sobre as janelas \mathbf{X}_t , extraindo padrões locais antes do processamento sequencial, o que permite capturar tanto dependências de curto prazo quanto interações de longo alcance nos dados (ZHANG et al., 2023; SONG; GUAN; YU, 2025).

Esse processo é ilustrado na Figura 2.6, que apresenta um exemplo esquemático da estruturação da entrada para modelos híbridos, destacando a integração entre janelas temporais, normalização e a organização em tensores espaço-temporais. Tais representações visuais reforçam a importância de uma preparação consistente dos dados antes do treinamento, evidenciando como a etapa de pré-processamento impacta diretamente a performance do modelo (XU et al., 2024; LI et al., 2025).

Enfim, o sucesso da modelagem depende diretamente da adequação dessas estratégias às características dos dados e do problema (ZHOU et al., 2023; CAO et al., 2025). O uso combinado de janelas temporais, normalização contextual e estruturas tensoriais bem definidas é fundamental para viabilizar modelos robustos, interpretáveis e eficientes (LI et al., 2025; SONG; GUAN; YU, 2025).




Figura 2.6: exemplo de janelamento e normalização em séries temporais multivariadas (Situ et al. (2024), Shan et al. (2023), Yu et al. (2023)).
(Fonte: elaborado pelo autor)

2.2.3 Desafios em dados reais: ruído, sazonalidade e dados ausentes

Dados ambientais reais captados por sensores IoT em zonas urbanas trazem consigo um conjunto de desafios que impactam diretamente a modelagem preditiva. Dentre os principais, destacam-se: *a presença de ruído, padrões sazonais complexos e a ocorrência de valores ausentes*. Tais características impõem a necessidade de técnicas robustas de pré-processamento e arquiteturas adaptativas (NARAYANA et al., 2024; ZAKARIA; JABBAR; SULAIMAN, 2023).

Ruído e medições inconsistentes

Sensores distribuídos em ambientes urbanos estão sujeitos a flutuações indesejadas nas medições, provocadas por fatores como interferência eletromagnética, variações abruptas de energia, falhas de calibração ou até vandalismo físico (SITU et al., 2024). Essas perturbações podem ser entendidas como um ruído aditivo que se sobrepõe ao sinal verdadeiro. Em geral, esse ruído apresenta comportamento estatístico próximo ao de uma distribuição normal com média zero e variância finita, embora em alguns casos assuma formas não gaussianas, o que torna necessária a aplicação de técnicas mais robustas de filtragem, como médias móveis, suavização por janelas ou filtros baseados em wavelets (SITU et al., 2024; LIU et al., 2019).

Outro desafio recorrente é a presença de *outliers* (valores atípicos), que podem distorcer significativamente o treinamento dos modelos de aprendizado de máquina. Para mitigar esse efeito, adotam-se estratégias como normalização robusta, baseada em medidas estatísticas menos sensíveis como a mediana, ou ainda métodos automáticos de detecção e exclusão de observações atípicas, utilizando algoritmos como Floresta de isolamento (IForest, do inglês *Isolation Forest*) ou DBSCAN (do inglês, *Density-Based Spatial Clustering of Applications with Noise*) (SHAN et al., 2023).

Sazonalidade e periodicidade múltipla

Muitas variáveis ambientais apresentam comportamento sazonal e cíclico (LEI et al., 2021; XU et al., 2021). Por exemplo, chuvas intensas tendem a ocorrer em determinadas épocas do ano, enquanto variações diárias de temperatura ou umidade estão associadas a ciclos horários (ZAKARIA; JABBAR; SULAIMAN, 2023; CAO et al., 2025). Esses padrões podem ser decompostos em três componentes principais: uma tendência de longo prazo, que mostra o crescimento ou declínio gradual dos valores; uma componente sazonal ou periódica, que reflete repetições regulares em intervalos diários, semanais ou anuais; e uma componente aleatória, que representa flutuações imprevisíveis (ZAKARIA; JABBAR; SULAIMAN, 2023).

Modelos modernos, como o APS-LSTM (FENG et al., 2024), foram projetados para lidar com múltiplas periodicidades de forma simultânea. Uma estratégia frequentemente utilizada é enriquecer os dados de entrada com variáveis que representam a posição temporal no ciclo, como a hora do dia ou o dia do ano, expressas em funções que permitem capturar padrões recorrentes (FENG et al., 2024; WANG et al., 2024).

Esse tipo de representação auxilia os modelos neurais a identificar relações sazonais e repetitivas mesmo em contextos de grande variabilidade climática, como os observados em áreas urbanas (WANG et al., 2024).

Dados ausentes

Um dos maiores desafios nos sistemas urbanos sensorizados é a ausência de dados — seja por falhas na comunicação, desconexões temporárias ou manutenção dos sensores. De forma geral, os dados podem estar ausentes como abaixo (LIU et al., 2019; ZAKARIA; JABBAR; SULAIMAN, 2023):

- MCAR (*Missing Completely At Random*): ausência aleatória;
- MAR (*Missing At Random*): ausência dependente de outras variáveis;
- MNAR (*Missing Not At Random*): ausência dependente da própria variável.

Abordagens simples como imputação com média ou interpolação linear podem ser úteis, mas frequentemente levam à perda de variabilidade. Técnicas mais avançadas incluem (SHAN et al., 2023):

- K-NN *imputation*: estima valores ausentes com base em vizinhos temporais e espaciais;
- GRU-D: redes recorrentes que integram diretamente a máscara de ausência no treinamento;
- *Attention-based Imputation*: mecanismos de atenção que ponderam janelas confiáveis ao redor do valor ausente.

De forma resumida, no contexto de sensores IoT, a ausência de dados pode ocorrer de forma geograficamente estruturada — por exemplo, quando todos os sensores de uma determinada região ficam off-line simultaneamente. Nessas situações, modelos baseados em GNNs com máscaras de conectividade dinâmicas têm se mostrado particularmente promissores para lidar com a distribuição espacial das falhas (GUAN et al., 2024; ZHANG et al., 2022).

Visualização e mitigação prática

A Figura 2.7 ilustra um trecho de uma série temporal ambiental real, no qual se evidenciam três dificuldades típicas: ruídos nas medições, lacunas de dados e padrões sazonais (SITU et al., 2024; LIU et al., 2019). Esses fatores, quando não tratados, podem comprometer a qualidade do treinamento e reduzir a capacidade de generalização dos modelos preditivos.




Figura 2.7: trecho de série temporal com ruído, dados ausentes e componente sazonal (Situ et al. (2024), Liu et al. (2019)).
(Fonte: elaborado pelo autor)

Para mitigar esses efeitos, diversas estratégias práticas podem ser aplicadas (ZAKARIA; JABBAR; SULAIMAN, 2023; SOARES et al., 2025). Em casos de ruído, utilizam-se filtros suavizadores (médias móveis, wavelets ou filtros de Kalman) que reduzem flutuações espúrias sem eliminar padrões relevantes (LIU et al., 2019; SHAN et al., 2023). No tratamento de dados ausentes, a imputação baseada em vizinhos próximos ou métodos probabilísticos fornece estimativas consistentes, preservando a coerência da série (NARAYANA et al., 2024; ESKANDARIAN et al., 2022). Já os padrões sazonais podem ser atenuados por técnicas de normalização contextual, como a padronização por hora do dia ou por estação do ano, permitindo que os modelos capturem relações mais estáveis (CAO et al., 2025; YU et al., 2023).

Enfim, como destacado por Choi et al. (2025) e Soares et al. (2025), o uso de *pipelines* robustos de pré-processamento é indispensável para garantir a integridade e a confiabilidade das predições. Tais etapas devem ser cuidadosamente validadas em conjuntos de séries independentes, evitando sobreajuste e a propagação de incertezas. Além disso, a documentação clara de cada decisão metodológica (ex.: interpolação adotada, tipo de normalização) é essencial para

reprodutibilidade e aplicação prática em sistemas de alerta precoce (PIADEH; BEHZADIAN; ALANI, 2022; SOARES et al., 2025).

3 METODOLOGIA

As etapas do projeto proposto compreendem:

1. Revisão da literatura: levantamento e análise crítica de trabalhos recentes, sobre predição de alagamentos urbanos utilizando redes neurais, incluindo CNNs, LSTMs, MLPs, ESNs, GNNs, Transformers e dentre outras, com foco em arquiteturas, métricas de desempenho e bases de dados utilizadas.
2. Desenvolvimento teórico: aprofundamento no estudo dos modelos de redes neurais mais promissores para a tarefa, com foco em séries temporais multivariadas. Será dada atenção especial à compreensão dos mecanismos de atenção, grafos espaciais e arquiteturas híbridas.
3. Preparação e pré-processamento dos dados: coleta e organização do dataset de sensores (chuva, nível d'água, pressão, vento etc.), tratamento de valores ausentes, normalização e divisão dos dados em conjuntos de treino, validação e teste.
4. Modelagem e simulações: implementação e treinamento dos modelos selecionados (ex: LSTM com atenção, GNNs, Transformers), com ajuste de hiperparâmetros, análise de overfitting, validação cruzada e comparação entre os modelos com base em métricas apropriadas (RMSE, MAE, F1 etc.).
5. Avaliação e análise crítica dos resultados: análise do desempenho dos modelos na predição de manchas de alagamento, identificação de pontos fortes e limitações de cada abordagem, e discussão sobre a aplicabilidade prática em contextos urbanos reais.
6. Escrita da dissertação e artigo: redação dos capítulos finais da dissertação, elaboração de gráficos, tabelas e figuras, bem como estruturação de pelo menos um artigo científico para submissão a periódico ou conferência.
7. Defesa: preparação da apresentação e realização da defesa pública da dissertação até o prazo final estabelecido.

O cronograma das atividades citadas pode ser visto na Tabela 3.1.

Etapa	03/25	04/25	05/25	06/25	07/25	08/25	09/25	10/25	11/25	12/25
Revisão da literatura	X	X	X							
Desenvolvimento teórico				X	X	X	X			
Preparação e pré-processamento dos dados				X	X	X	X			
Modelagem e simulações					X	X	X			
Avaliação e análise crítica dos resultados							X	X		
Finalização da escrita da dissertação e artigo(s)							X	X	X	
Revisões finais, banca e defesa									X	X

Tabela 3.1: Cronograma das atividades previstas

4 RELAÇÃO DE PERIÓDICOS E EVENTOS CIENTÍFICOS COM POTENCIAL PARA PUBLICAÇÃO

Abaixo, apresento uma relação de periódicos e eventos científicos com potencial para publicação de trabalhos relacionados à predição de manchas de alagamento utilizando redes neurais, aprendizado de máquina e sensores urbanos.

Periódicos

A seguir, são listados os principais periódicos científicos relevantes:

- **Hidrologia, Previsão de Enchentes e Modelagem Ambiental**
 - *Journal of Hydrology* – Elsevier
 - *Water Research* – Elsevier
 - *Hydrology and Earth System Sciences (HESS)* – Copernicus/EGU
 - *Water (MDPI)*
- **Inteligência Artificial, Machine Learning e Computação Aplicada**
 - *Engineering Applications of Artificial Intelligence* – Elsevier
 - *Neurocomputing* – Elsevier
 - *Applied Soft Computing* – Elsevier
 - *Expert Systems with Applications* – Elsevier
- **Cidades Inteligentes, IoT e Engenharia Urbana**
 - *Sustainable Cities and Society* – Elsevier
 - *IEEE Internet of Things Journal* – IEEE
 - *Smart Cities* – MDPI

Eventos Científicos

Abaixo são listados eventos científicos com escopo alinhado ao tema da pesquisa:

- **Internacionais**

- IEEE International Conference on Big Data (IEEE BigData)
- International Joint Conference on Neural Networks (IJCNN)
- European Geosciences Union (EGU) General Assembly
- International Conference on Flood Management (ICFM)
- ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)

- **Nacionais (Brasil)**

- Simpósio Brasileiro de Redes Neurais (SBRN)
- Congresso Brasileiro de Automática (CBA)
- Simpósio Brasileiro de Sensoriamento Remoto (SBSR)
- Congresso Brasileiro de Engenharia Sanitária e Ambiental (CBESA)
- Simpósio Brasileiro de Sistemas de Informação (SBSI)

5 RECURSOS

Já dispomos de um conjunto inicial de séries históricas provenientes de sensores ambientais instalados em pontos críticos da cidade do Rio de Janeiro (precipitação, nível d'água, umidade, pressão, velocidade do vento e temperatura), provenientes de estações meteorológicas do COR-Rio e também com possíveis datasets do INMET e da start up Noah Smarty Cities o que permitirá treinar e validar modelos supervisionados com janelas temporais e horizontes de previsão definidos. O ambiente de desenvolvimento está consolidado em Python, com bibliotecas maduras para modelagem (scikit-learn, TensorFlow e PyTorch) e para manipulação de dados (pandas, NumPy), possibilitando desde *baselines* lineares até arquiteturas profundas (LSTM, CNN-LSTM, Transformers). Em termos computacionais, há disponibilidade de GPU local e ou acesso ao servidor da UFSC, viabilizando o treinamento de modelos de maior porte dentro de prazos compatíveis. Em conjunto, esses fatores tornam a proposta possível, pois há dados relevantes, ferramentas consolidadas e capacidade de processamento para conduzir os experimentos previstos.

Abaixo segue uma listagem dos recursos disponíveis até o momento:

- Dataset sensorial real (precipitação, nível da água, velocidade do vento, umidade, pressão atmosférica, temperatura e etc) de estações meteorológicas do COR-Rio,
- Dataset sensorial real do projeto Digital Twin da Start up Noah Smart Cities de uma região conhecida como bacia do canal do mangue na cidade do Rio de Janeiro,
- Ambiente de desenvolvimento Python (TensorFlow, Pytorch..),
- Computador com GPU (Possível utilização de servidor da Ufsc).

REFERÊNCIAS

- AHMED, A.; RIO-CHANONA, E. A. del; MERCANGÖZ, M. Linearizing nonlinear dynamics using deep learning. *Computers Chemical Engineering*, v. 170, p. 108104, 2023. DOI: 10.1016/j.compchemeng.2022.108104.
- BENTIVOGLIO, R. et al. Deep learning methods for flood mapping: a review of existing applications and future research directions. *Hydrology and Earth System Sciences*, Copernicus Publications, v. 26, n. 16, p. 4345–4378, 2022. DOI: 10.5194/hess-26-4345-2022.
- BEVEN, K. J. *Rainfall-Runoff Modelling: The Primer*. 2nd. ed. Chichester, UK: Wiley-Blackwell, 2011. ISBN 978-0470748752.
- CAO, X. et al. U-rnn high-resolution spatiotemporal nowcasting of urban flooding. *Journal of Hydrology*, Elsevier, v. 659, p. 133117, October 2025. DOI: 10.1016/j.jhydrol.2025.133117.
- CHOI, H. et al. Flo-sr: Deep learning-based urban flood super-resolution model. *Journal of Hydrology*, Elsevier, v. 661, p. 133529, 2025. DOI: 10.1016/j.jhydrol.2025.133529.
- ESKANDARIAN, P. et al. A novel artificial neural network improves multivariate feature extraction in predicting correlated multivariate time series. *Applied Soft Computing*, v. 128, p. 109460, 2022. DOI: 10.1016/j.asoc.2022.109460.
- FENG, J. et al. Aps-lstm: Exploiting multi-periodicity and diverse spatial dependencies for flood forecasting. *arXiv preprint arXiv:2412.06835*, 2024. DOI: 10.48550/arXiv.2412.06835.
- GONG, R.; LI, J.; WANG, C. Remaining useful life prediction based on multisensor fusion and attention tcn-bigru model. *IEEE Sensors Journal*, IEEE, v. 22, n. 21, p. 21101–21110, 2022. DOI: 10.1109/JSEN.2022.3208753.
- GUAN, Z. et al. Stfs-urban: Spatio-temporal flood simulation model for urban areas. *Journal of Environmental Management*, Elsevier, v. 349, p. 119289, 2024. DOI: 10.1016/j.jenvman.2023.119289.
- GUO, K.; GUAN, M.; YU, D. Urban surface water flood modelling – a comprehensive review of current models and future challenges. *Hydrology and Earth System Sciences*, v. 25, n. 5, p. 2843–2860, 2021. DOI: 10.5194/hess-25-2843-2021.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, MIT Press, v. 9, n. 8, p. 1735–1780, 1997. DOI: 10.1162/neco.1997.9.8.1735.
- KILINC, H. C. et al. Enhancing hydrological time series forecasting with a hybrid bayesian-convlstm model optimized by particle swarm optimization. *Acta Geophysica*, Springer, 2025. DOI: 10.1007/s11600-025-01570-0.
- KOYA, S. R.; ROY, T. Temporal fusion transformers for streamflow prediction: Value of combining attention with recurrence. *Journal of Hydrology*, Elsevier, v. 637, p. 131301, 2024. DOI: 10.1016/j.jhydrol.2024.131301.

- LEI, X. et al. Urban flood modeling using deep-learning approaches in seoul, south korea. *Journal of Hydrology*, v. 601, p. 126684, 2021. DOI: 10.1016/j.jhydrol.2021.126684.
- LI, Z. et al. Artificial intelligence-incorporated prediction for urban flooding processes in the past 20 years: A critical review. *Environmental Modelling Software*, v. 173, p. 106525, 2025. DOI: 10.1016/j.envsoft.2025.106525.
- LIU, J. et al. Uncertainties of urban flood modeling: Influence of parameters for different underlying surfaces. *Environmental Research*, Elsevier, v. 182, p. 108929, 2020. DOI: 10.1016/j.envres.2019.108929.
- LIU, Y. et al. Dstp-rnn: A dual-stage two-phase attention-based recurrent neural networks for long-term and multivariate time series prediction. *arXiv preprint arXiv:1904.07464*, 2019. DOI: 10.48550/arXiv.1904.07464.
- LöWE, R. et al. U-flood – topographic deep learning for predicting urban pluvial flood water depth. *Journal of Hydrology*, Elsevier, v. 603, n. Part A, p. 126898, 2021. DOI: 10.1016/j.jhydrol.2021.126898.
- MOSAVI, A.; OZTURK, P.; CHAU, K.-W. Flood prediction using machine learning models: Literature review. *Water*, MDPI, v. 10, n. 11, p. 1536, 2018. DOI: 10.3390/w10111536.
- NARAYANA, T. L. et al. Advances in real-time smart monitoring of environmental parameters using iot and sensors. *Heliyon*, v. 11, p. e28195, 2024. DOI: 10.1016/j.heliyon.2024.e28195.
- NKWUNONWO, U. C.; WHITWORTH, M.; BAILY, B. A review of the current status of flood modelling for urban flood risk management in the developing countries. *Scientific African*, Elsevier, v. 7, p. e00269, 2020. DOI: 10.1016/j.sciaf.2020.e00269.
- OKACHA, A. et al. Enhancing flood forecasting accuracy in data-scarce regions through advanced modeling approaches. *Journal of Hydrology*, Elsevier, v. 645, p. 132283, 2024. DOI: 10.1016/j.jhydrol.2024.132283.
- PIADEH, F.; BEHZADIAN, K.; ALANI, A. M. A critical review of real-time modelling of flood forecasting in urban drainage systems. *Journal of Hydrology*, v. 607, p. 127476, 2022. DOI: 10.1016/j.jhydrol.2022.127476.
- RASHEED, Z. et al. Combining global precipitation data and machine learning to predict flood peaks in ungauged areas with similar climate. *Advances in Water Resources*, Elsevier, v. 184, p. 104781, 2024. DOI: 10.1016/j.advwatres.2024.104781.
- SEYDI, S. T. et al. Comparison of machine learning algorithms for flood susceptibility mapping. *Remote Sensing*, MDPI, v. 15, n. 1, p. 192, 2022. DOI: 10.3390/rs15010192.
- SHAN, S. et al. A machine learning framework for enhancing short-term water demand forecasting using attention-bilstm networks integrated with xgboost residual correction. *Water*, MDPI, v. 15, n. 20, p. 3605, 2023. DOI: 10.3390/w15203605.
- SITU, Z. et al. Improving urban flood prediction using lstm-deeplabv3+ and bayesian optimization with spatiotemporal feature fusion. *Journal of Hydrology*, Elsevier, v. 630, p. 130743, 2024. DOI: 10.1016/j.jhydrol.2024.130743.

SOARES, J. A. et al. MI4ff: A machine-learning framework for flash flood forecasting applied to a brazilian watershed. *Journal of Hydrology*, Elsevier, v. 626, p. 132674, 2025. DOI: 10.1016/j.jhydrol.2025.132674.

SONG, W.; GUAN, M.; YU, D. Swinflood: A hybrid cnn-swin transformer model for rapid spatiotemporal flood simulation. *Journal of Hydrology*, Elsevier, v. 660, n. Part A, p. 133280, 2025. DOI: 10.1016/j.jhydrol.2025.133280.

SYEED, M. M. A. et al. Flood prediction using machine learning models. *arXiv preprint arXiv:2208.01234*, 2022. DOI: 10.48550/arXiv.2208.01234.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. Long Beach, CA, USA: [s.n.], 2017. p. 5998–6008. DOI: 10.48550/arXiv.1706.03762.

WANG, H. et al. Prediction of flood risk levels of urban flooded points through using machine learning with unbalanced data. *Journal of Hydrology*, Elsevier, v. 630, p. 130742, February 2024. DOI: 10.1016/j.jhydrol.2024.130742.

XU, Q. et al. Large-scale flood modeling and forecasting with floodcast. *Water Research*, Elsevier, v. 264, p. 122162, 2024. DOI: 10.1016/j.watres.2024.122162.

XU, Y. et al. Application of temporal convolutional network for flood forecasting. *Hydrology Research*, v. 52, n. 6, p. 1455–1468, 2021. DOI: 10.2166/nh.2021.021.

YU, H. et al. Improving the accuracy of flood susceptibility prediction by combining machine learning models and the expanded flood inventory data. *Remote Sensing*, MDPI, v. 15, n. 14, p. 3601, 2023. DOI: 10.3390/rs15143601.

ZAKARIA, M. I.; JABBAR, W. A.; SULAIMAN, N. Development of a smart sensing unit for lorawan-based iot flood monitoring and warning system in catchment areas. *Internet of Things and Cyber-Physical Systems*, v. 3, p. 249–261, 2023. DOI: 10.1016/j.iotcps.2023.04.005.

ZHANG, X. et al. Advance prediction of coastal groundwater levels with temporal convolutional and long short-term memory networks. *Hydrology and Earth System Sciences*, v. 27, p. 83–96, 2023. DOI: 10.5194/hess-27-83-2023.

ZHANG, Y. et al. Generalization of an encoder-decoder lstm model for flood prediction in ungauged catchments. *Journal of Hydrology*, Elsevier, v. 614, n. Part B, p. 128577, 2022. DOI: 10.1016/j.jhydrol.2022.128577.

ZHOU, H. et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2021. v. 35, n. 12, p. 11106–11115. DOI: 10.1609/aaai.v35i12.17325.

ZHOU, Q. et al. A deep-learning-technique-based data-driven model for accurate and rapid flood predictions in temporal and spatial dimensions. *Hydrology and Earth System Sciences*, EGU Copernicus Publications, v. 27, n. 9, p. 1791–1808, 2023. DOI: 10.5194/hess-27-1791-2023.